



FANNY LESEACH
ADAM BRAHMA

Rapport IA

2025

SOMMAIRE

Introduction

Réalisation du Besoin client 1 :

**regroupement des navires
selon leur direction et
visualisation graphique**

Réalisation du Besoin client 2:

**Modèle de prédiction du type
de navire**

Réalisation du Besoin client 3:

**Prédiction de la trajectoire
des navires**

Conclusion

INTRODUCTION

Pour ce projet, on a travaillé à partir de données AIS, qui permettent de suivre les navires en mer, avec l'objectif de mieux comprendre leurs comportements de navigation.

Le projet était structuré autour de trois besoins clients :

- Regrouper les navires selon des trajectoires similaires
- Prédire le type de navire à partir de ses caractéristiques
- Estimer sa position future à différents moments

Pour y répondre, on a utilisé différentes techniques d'intelligence artificielle : du clustering, de la classification, et de la prédiction sur séries temporelles.

Ce projet nous a permis de mettre en pratique ce qu'on a appris cette année, tout en découvrant les vraies étapes d'un projet IA : traitement des données, choix des méthodes, analyse des résultats, et mise en forme finale.

Dans ce rapport, on retrace notre démarche, les décisions qu'on a prises, et ce que ça a donné pour chaque besoin.

BESOIN CLIENT 1

Dans cette partie, nous nous sommes concentrés sur le besoin client 1, qui consiste à regrouper les navires selon des comportements de navigation similaires.

Pour cela, nous avons décidé de travailler sur la direction des navires (COG) et exploré différentes méthodes de clustering non supervisé, en utilisant notamment la direction de navigation (COG), transformée en coordonnées cartésiennes (x, y) pour éviter les erreurs liées à la circularité (par exemple, 0° et 360° sont proches).

L'objectif final était de rendre ces clusters visibles sur une carte, pour faciliter l'analyse des trajectoires et comportements maritimes.

1. Clustering par K-means

Pour regrouper les navires selon leur direction de navigation, nous avons utilisé l'algorithme K-means sur les coordonnées (x,y) calculées à partir de l'angle COG, qui représente la direction suivie par le navire.

Le principe de K-means est simple : il choisit k centres (appelés centroides), puis regroupe chaque point au centre le plus proche, et ajuste les centres jusqu'à ce que les groupes se stabilisent.

On a testé plusieurs valeurs de k, mais seules deux avaient du sens dans notre cas :

- k=4, qui correspond aux grandes directions (nord, sud, est, ouest)
- k=8, qui permet de distinguer des directions plus fines comme nord-est, nord-ouest, etc.

On a finalement retenu $k=8$, car les indicateurs de qualité du clustering étaient meilleurs :

- Silhouette score : 0.545
→ Les groupes sont plutôt bien séparés, même s'il reste un peu de mélange entre certains.
- Calinski-Harabasz : 146 418
→ Très bon score, qui montre que les clusters sont bien distincts.
- Davies-Bouldin : 0.534
→ Correct, ce qui veut dire que les clusters sont assez compacts et ne se chevauchent pas trop.

Globalement, ces résultats nous indiquent que le regroupement pour $k=8$ est cohérent et fonctionne bien pour notre cas.

2. Clustering hiérarchique

Le clustering hiérarchique fonctionne en regroupant progressivement les points les plus proches les uns des autres, jusqu'à former un nombre de clusters défini.

On a choisi de le tester pour essayer d'améliorer les résultats du K-means, qui étaient corrects mais pas parfaits.

Au final, les scores sont très proches de ceux du K-means, sans amélioration notable. La structure des groupes reste cohérente, mais pas plus précise qu'avec la méthode précédente.

3. Clustering HDBSCAN

On a aussi testé HDBSCAN, qui a l'avantage de détecter automatiquement le nombre de clusters, sans avoir à le choisir.


Mais dans notre cas, c'est justement un souci : comme on veut regrouper les navires selon 4 ou 8 directions bien précises, ne pas pouvoir fixer le nombre de groupes limite l'intérêt de cette méthode.

On peut quand même essayer de jouer sur la taille minimale des clusters pour influencer le résultat. Mais ça reste fragile : ici, avec un échantillon de 1000 points, HDBSCAN a formé seulement 2 clusters (Est et Ouest), car dès qu'il y a un petit déséquilibre dans les données, certains clusters disparaissent.

Au final, ça ne correspond pas à ce qu'on cherche. La méthode est intéressante, mais pas adaptée à notre besoin.

4. Représentation graphique

Navires regroupés par direction de navigation avec la methode kmeans



On a choisi de représenter les résultats obtenus avec K-means, car c'est la méthode qui donnait les résultats les plus cohérents pour notre cas. Elle permettait de fixer précisément 8 directions (nord, nord-est, est, etc.), ce qui correspondait bien à notre objectif, et les scores de clustering étaient meilleurs que ceux des autres méthodes testées.

Pour chaque groupe, on a calculé la direction moyenne, puis on a attribué une direction à chaque navire.

Sur la carte, les navires sont affichés avec une couleur différente selon leur direction. Ça permet de visualiser clairement les grands axes de navigation : par exemple, on voit bien des mouvements vers le sud depuis la côte ou des trajets est-ouest très marqués.

Grâce à cette carte, on comprend rapidement comment se répartissent les trajets en mer, ce qui répond parfaitement à l'objectif du besoin client 1.

Besoin client 2

L'objectif de cette partie du projet était de prédire le type de navire (VesselType) à partir des données issues du système AIS (Automatic Identification System), en utilisant des algorithmes de classification supervisée. Ce travail s'inscrit dans une logique de création d'un modèle prédictif robuste, réutilisable et intégrable dans une application web interactive.

1) Selection variables:

Avant d'entraîner un modèle de machine learning, il était nécessaire d'identifier les variables les plus pertinentes. Une étude de corrélation a été menée entre les différentes variables disponibles et la variable cible (VesselType). Nous avons retenu uniquement celles présentant une corrélation supérieure à 0.3, afin d'assurer une bonne capacité explicative tout en réduisant la dimensionnalité du problème.

Voici les résultats des coefficients de corrélation :

Variables	Coefficient de corrélation
Cargo	0.847490
Draft	0.585147
Width	0.545125
Lenght	0.510083
SOG	0.008060
COG	-0.023292
Heading	-0.098711


Les variables les moins corrélées, comme *SOG*, *COG* ou *Heading*, ont été écartées du jeu de données pour éviter le bruit et améliorer la précision du modèle.

2) préparation des données:

Les données brutes du fichier Export_IA.csv ont été explorées, nettoyées (malgré un pré-nettoyage déjà effectué en Big Data), puis filtrées pour ne conserver que les colonnes pertinentes.

Nous avons construit deux ensembles :

- X : les variables explicatives (*Cargo*, *Draft*, *Width*, *Length*)
- y : la variable cible (*VesselType*)



```
Aperçu des données filtrées :
  Cargo  Draft  Width  Length  VesselType
0      83   10.0    28    183         80
1      60    2.3     9     47         60
2      60    1.9     9     30         60
3      70    5.0    20     92         70
4      80    6.5    25    160         80

Distribution de VesselType :
VesselType
70      85613
80      70061
60      31504
79       5544
71       5452
89       4491
82       2511
61       1840
74       1077
84        996
```

Ces jeux de données ont été sauvegardés dans X_prepared.csv et y_prepared.csv, afin de permettre leur réutilisation dans d'autres scripts sans avoir à répéter les étapes de préparation.

3) le split des données:

Une fois les données préparées et nettoyées, il est essentiel de les diviser en deux ensembles distincts :

- un ensemble d'entraînement pour apprendre le modèle,
- un ensemble de test pour évaluer sa capacité à généraliser sur de nouvelles données.

Cette étape appelée split permet de simuler un scénario réel où le modèle est confronté à des cas qu'il n'a jamais vus.

Dans notre cas, nous avons utilisé un rapport classique 80/20 :

- 80 % des données pour l'entraînement (X_train, y_train)
- 20 % pour le test (X_test, y_test)

Cette séparation garantit une évaluation fiable et impartiale des performances du modèle lors de la phase suivante.

Après la séparation des données en deux sous-ensembles (train et test), chaque partie a été sauvegardée dans un fichier CSV distinct afin de pouvoir être réutilisée facilement dans les étapes suivantes.

Les fichiers générés sont les suivants :

Fichier	Contenu
X_train.csv	Données d'entrée pour l'entraînement
X_test.csv	Données d'entrée pour les tests
y_train.csv	Cibles (types de navires) pour l'entraînement
y_test.csv	Cibles pour tester le modèle

4) Modele de classification:


Un modèle Random Forest Classifier (100 arbres) a été utilisé pour prédire le type de navire (*VesselType*), en raison de sa robustesse face aux données hétérogènes. Les données ont été normalisées pour harmoniser l'échelle des variables, puis le modèle a été entraîné sur l'ensemble *X_train_scaled*. Les prédictions sur *X_test_scaled* ont ensuite été évaluées via un rapport de classification détaillant précision, rappel et f1-score.

- Le rapport de classification (*classification_report*) qui donne des métriques précises comme la précision, le rappel et le f1-score pour chaque type de navire.

Rapport de classification :

	precision	recall	f1-score	support
60	1.00	1.00	1.00	6301
61	1.00	1.00	1.00	368
70	1.00	1.00	1.00	17123
71	1.00	1.00	1.00	1091
74	1.00	1.00	1.00	215
79	1.00	1.00	1.00	1109
80	1.00	1.00	1.00	14012
82	1.00	1.00	1.00	502
84	1.00	1.00	1.00	199
89	1.00	1.00	1.00	898
accuracy			1.00	41818
macro avg	1.00	1.00	1.00	41818
weighted avg	1.00	1.00	1.00	41818

- La matrice de confusion, visualisée avec seaborn, qui permet d'identifier les classes les plus confondues par le modèle.



Ces outils nous ont permis de confirmer que le modèle Random Forest était très performant, atteignant une accuracy globale supérieure à 98 %, avec une précision élevée sur les classes majoritaires comme les types 70, 80 et 60

5) prédiction:

Un script interactif prediction.py a été développé pour charger le modèle (model.pkl) et le scaler, permettant à l'utilisateur de saisir manuellement les données du navire. Celles-ci sont normalisées puis utilisées pour prédire le *Vesse/Type*. Le modèle Random Forest a ensuite été comparé à un DummyClassifier (précision faible) et un KNeighborsClassifier (précision élevée mais risque d'overfitting).

Comparaison des modèles:

Trois modèles ont été comparés pour prédire le *Vesse/Type* :

- DummyClassifier (baseline) : faible précision (~41 %), ne fait que prédire la classe la plus fréquente.
- RandomForestClassifier : excellente performance (~100 %), bon équilibre précision/rappel, robuste face au déséquilibre des classes.
- KNeighborsClassifier : très précis mais probablement en overfitting, avec un risque de mémorisation des données.

Conclusion : Random Forest est le modèle le plus fiable et stable pour ce cas d'usage.

Besoin client 3

Dans le cadre du besoin du client 3, l'objectif était de prédire la position GPS future (latitude, longitude) d'un navire, à partir de ses 5 dernières positions enregistrées. Ce travail vise à anticiper la trajectoire d'un navire à court terme, en exploitant les données issues du système AIS.

Pour cela, les données ont été regroupées par navire (MMSI), puis triées chronologiquement (BaseDateTime). À partir de ces trajectoires, nous avons construit des séquences glissantes : 5 points consécutifs ont servi d'entrée, et le 6e point comme position cible à prédire.

Un modèle de régression linéaire a été utilisé pour apprendre la relation entre les séquences passées et la position suivante. Les données d'entrée ont été normalisées afin d'améliorer la stabilité et la précision du modèle. Le modèle a ensuite été entraîné sur l'ensemble des séquences et évalué sur les mêmes données.

```
Prédiction du 6 eme point : [ 25.9600896 -97.37841811 ] | Réel : [ 25.95848 -97.37882 ]
Prédiction du 7 eme point : [ 25.96010814 -97.37841955 ] | Réel : [ 25.95846 -97.37883 ]
Prédiction du 8 eme point : [ 25.96008997 -97.37842998 ] | Réel : [ 25.95849 -97.37879 ]
Prédiction du 9 eme point : [ 25.96011634 -97.37838609 ] | Réel : [ 25.95846 -97.37878 ]
Prédiction du 10 eme point : [ 25.96008941 -97.3783791 ] | Réel : [ 25.95842 -97.3788 ]
Prédiction du 11 eme point : [ 25.96004846 -97.37839503 ] | Réel : [ 25.95841 -97.37882 ]
Prédiction du 12 eme point : [ 25.9600394 -97.37842142 ] | Réel : [ 25.95846 -97.37879 ]
Prédiction du 13 eme point : [ 25.96008649 -97.37838728 ] | Réel : [ 25.95845 -97.37879 ]
Prédiction du 14 eme point : [ 25.96007857 -97.37838531 ] | Réel : [ 25.95845 -97.37881 ]
Prédiction du 15 eme point : [ 25.9600785 -97.37840705 ] | Réel : [ 25.95843 -97.37879 ]
Prédiction du 16 eme point : [ 25.96005916 -97.37839125 ] | Réel : [ 25.95845 -97.37878 ]
Prédiction du 17 eme point : [ 25.96007807 -97.37837834 ] | Réel : [ 25.95847 -97.3788 ]
Prédiction du 18 eme point : [ 25.96009858 -97.37839935 ] | Réel : [ 25.95845 -97.37885 ]
Prédiction du 19 eme point : [ 25.96008002 -97.37844747 ] | Réel : [ 25.95841 -97.37876 ]
Prédiction du 20 eme point : [ 25.96003685 -97.37835605 ] | Réel : [ 25.95844 -97.37877 ]
Prédiction du 21 eme point : [ 25.96006965 -97.37837285 ] | Réel : [ 25.95845 -97.37878 ]
Prédiction du 22 eme point : [ 25.96007654 -97.37837545 ] | Réel : [ 25.95845 -97.37881 ]
Prédiction du 23 eme point : [ 25.96007924 -97.37840583 ] | Réel : [ 25.95845 -97.37877 ]
Prédiction du 24 eme point : [ 25.96007803 -97.37836967 ] | Réel : [ 25.95843 -97.37878 ]
Prédiction du 25 eme point : [ 25.96005997 -97.3783798 ] | Réel : [ 25.95843 -97.37878 ]
Prédiction du 26 eme point : [ 25.96005758 -97.37837749 ] | Réel : [ 25.95847 -97.37878 ]
Prédiction du 27 eme point : [ 25.96009822 -97.37837988 ] | Réel : [ 25.95844 -97.37883 ]
Prédiction du 28 eme point : [ 25.96007038 -97.37842768 ] | Réel : [ 25.95847 -97.3788 ]
...
Prédiction du 68989 eme point : [ 29.90056018 -90.08115613 ] | Réel : [ 29.90115 -90.08112 ]
Prédiction du 68990 eme point : [ 29.90057816 -90.08115594 ] | Réel : [ 29.90116 -90.08113 ]
Prédiction du 68991 eme point : [ 29.90059005 -90.08116747 ] | Réel : [ 29.90115 -90.08112 ]
Prédiction du 68992 eme point : [ 29.900579 -90.08115473 ] | Réel : [ 29.90114 -90.08111 ]
```

Les résultats montrent que le modèle est capable de produire des prédictions proches de la réalité, avec une légère tendance à surestimer la position, probablement due à la simplicité du modèle (qui suppose une trajectoire linéaire).

CONCLUSION

Ce projet nous a permis de concevoir et d'évaluer plusieurs modèles d'intelligence artificielle à partir de données AIS, en réponse à trois besoins clients différents. Nous avons développé des approches de classification, de régression et de clustering, en travaillant sur des données déjà préparées.

Chaque cas nous a permis de manipuler des outils concrets (scikit-learn, indicateurs d'évaluation, normalisation), et de mieux comprendre comment adapter un modèle au besoin exprimé.

Ce travail nous a donné une expérience complète, de la modélisation à l'interprétation, en passant par la comparaison des performances.