

Rapport BIG DATA



ADAM BRAHMA
FANNY LE SEACH

2025

SOMMAIRE

1. **Introduction**
2. **Exploration des données et nettoyage des fichiers**
3. **Visualisation des données sur des graphiques**
4. **Visualisation des données sur une carte**
5. **Etude des corrélations entre variables**
6. **Conclusion**

INTRODUCTION

Dans le cadre de notre troisième année d'école d'ingénieur, nous avons réalisé un projet Big Data visant à exploiter un jeu de données issu du système d'identification automatique (AIS) des navires. Le système AIS est utilisé à l'échelle mondiale pour suivre les positions, les vitesses et d'autres informations techniques sur les navires.

L'objectif de ce projet est de concevoir une application d'analyse et de visualisation des données AIS, en combinant des compétences en traitement de données, intelligence artificielle, statistique, visualisation.

Nous avons travaillé à partir d'un fichier de données brutes (vessel-total-clean.csv) comprenant des milliers de données sur des bateaux opérant dans le golfe du Mexique.

Exploration des données et nettoyage des fichiers

Le jeu de données utilisé pour ce projet provient du fichier vessel-total-clean.csv, contenant des informations issues du système AIS (Automatic Identification System). Chaque ligne du fichier représente un signal émis par un navire, avec un ensemble de données technique. Voici les principales colonnes et leurs descriptions.

Variable	Description	Exemple
MMSI	Identifiant unique du navire (Maritime Mobile Service Identity)	477220100
BaseDateTime	Date et heure UTC de l'émission du signal	2017-02-01T20:05:07
LAT, LON	Latitude et longitude du navire au moment de l'émission	42.35137, -71.04182
SOG	Vitesse sur le fond (Speed Over Ground)	5.9 nœuds
COG	Cap sur le fond (Course Over Ground)	47.5 degrés
Heading	Cap réel du navire	45.1 degrés
VesselName	Nom du navire	OOCL Malaysia
IMO	Numéro de l'Organisation Maritime Internationale	IMO9627980
CallSign	Indicatif d'appel radio	VRME7
VesselType	Type de navire (codé)	70
Status	Statut de navigation (ex. : en mouvement, ancré)	3
Length, Width, Draft	Dimensions du navire (longueur, largeur, tirant d'eau)	71.0, 12.0, 3.5


Cargo	Type de cargaison (codé)	70
TransceiverClass	Type de transpondeur AIS (A ou B)	A

On peut dès alors s'apercevoir que le fichier contient des variables permettent une analyse riche et variée, aussi bien du point de vue spatial (localisation), que technique (dimensions, vitesse) ou typologique (type de bateau, cargaison).

Avant de plonger dans des analyses, on a commencé par simplement regarder ce que contient le fichier. Pour ça, on a utilisé deux fonctions bien pratiques : `summary()` et `skim()`. `Summary()` nous a permis d'avoir les valeurs minimales, maximales, moyennes et médianes pour chaque colonne numérique. `Skim` nous permet d'obtenir une vue encore plus complète, elle nous donne le nombre de valeurs sont manquantes par variable ou les colonnes qui posent problème par exemple.

Grâce à ces outils, on a commencé à mieux comprendre notre jeu de données. On a repéré certaines anomalies (des vitesses très élevées ou des dimensions incohérentes). Il a donc fallut nettoyer le fichier pour enlever les valeurs aberrantes ou manquantes et les doublons. On s'aperçois qu'il n'y a pas de doublons et on arrive en tout à 34 441 lignes contenant des valeurs aberrantes et 176 687 lignes contenant des valeurs manquantes. On est donc passer d'un fichier qui contenait 150 bateaux à un fichier qui n'en contient plus que 93. On enregistre ensuite le nouveau fichier nettoyé et le renomme: "export_IA.csv" qu'on peu retrouver dans le dossier de ce projet.

Visualisation des données sur des graphiques




L'histogramme ci-dessus représente les dix ports les plus fréquentés du golfe du Mexique, en fonction du nombre de navires distincts détectés dans chaque zone portuaire. Les données sont basées sur les identifiants uniques des navires (MMSI) issus du système AIS. L'axe des abscisses indique les noms des ports, tandis que l'axe des ordonnées représente le nombre total de navires ayant transité par chaque port.

Le Port of Houston se distingue très nettement comme le port le plus actif, avec environ 40 navires distincts. Ce résultat est cohérent avec sa position stratégique en tant que principal hub industriel et pétrochimique de la région. Il est suivi de près par le Port Fourchon et le Port of Galveston, qui enregistrent chacun plus de 30 navires. Le Port of New Orleans, quant à lui, occupe également une place importante, avec près de 28 navires.

D'autres ports comme Port Everglades, Port of Mobile et Port of Tampa présentent également une activité significative, avec une fréquentation située entre 22 et 26 navires. Enfin, les ports de Corpus Christi, Pascagoula et Freeport complètent le classement, avec une fréquentation plus modérée, mais tout de même suffisante pour apparaître dans les dix premiers.

Ces résultats illustrent une forte concentration de l'activité maritime autour de quelques grands ports stratégiques du golfe du Mexique. La fréquentation élevée de ces ports est probablement liée à leur rôle économique majeur, à leur accessibilité maritime, ainsi qu'à leur spécialisation (fret, croisières, industrie offshore, etc.).


Nuage de points de la vitesse en fonction de la longueur des bateaux (avant le nettoyage)



Le diagramme en nuage de points présente la relation entre la longueur des bateaux (en mètres) et leur vitesse sur le sol (SOG, en nœuds), à partir du fichier *vessel-total-clean.csv*. La majorité des bateaux mesurent moins de 100 mètres et naviguent à des vitesses comprises entre 0 et 25 nœuds, bien que

des vitesses extrêmes allant jusqu'à 100 nœuds apparaissent, suggérant la présence d'erreurs ou d'outliers. **La dispersion importante des points indique qu'il n'existe pas de lien clair entre la longueur et la vitesse,** d'autres facteurs tels que le type de navire, la charge ou les conditions météorologiques ayant probablement un impact plus significatif. Les données utilisées ont été filtrées pour ne conserver que les valeurs valides de longueur et de vitesse.

Nuage de points de la vitesse en fonction de la longueur des bateaux (après le nettoyage)




Après nettoyage, le nuage de points se recentrerait autour des valeurs typiques, réduisant la dispersion et mettant en évidence une relation plus claire entre la longueur et la vitesse. Les points extrêmes, qui masquent la structure des données, seraient exclus, rendant l'analyse statistique (ex. : corrélation ou régression) plus fiable.

Le nettoyage des données est une étape cruciale pour garantir la qualité de l'analyse. Il permet de supprimer les valeurs aberrantes qui déforment le nuage de points, offrant une représentation plus précise et utile pour interpréter la relation entre la longueur des bateaux et leur vitesse.

Camenbert des Repartition des bateaux par type

Avant nettoyage

Répartition des bateaux par type




Le diagramme circulaire illustre la répartition des types de navires présents dans le dataset *vessel-total-clean.csv*. On observe que trois catégories dominent largement l'ensemble : les "Cargo" représentent la plus grande proportion, suivis par les "Tanker" et les "Passenger". Les autres types de navires, tels que les "Fishing", "Pleasure Craft", "Tug", "High-Speed Craft" ou encore "Military Ops", occupent des parts beaucoup plus réduites. Cette distribution montre une prédominance des navires commerciaux et de transport par rapport aux autres types de navigation. Le graphique permet ainsi de visualiser rapidement la composition de la flotte analysée.

Camenbert des Repartition des bateaux par type

Après nettoyage


Après le processus de nettoyage, le diagramme circulaire montre une répartition ajustée des types de bateaux. Les catégories comme Cargo, Tanker, et Passenger restent prédominantes, mais les parts des autres types (ex. : Fishing, Pleasure Craft) sont mieux équilibrées et reflètent une structure de données plus cohérent. Le nettoyage a permis d'éliminer les anomalies (ex. : doublons, erreurs de codage), offrant une représentation plus précise de la composition réelle de la flotte. Le diagramme devient plus lisible et les proportions des catégories sont mieux définies. Cela permet d'identifier clairement les types dominants et d'améliorer la fiabilité des conclusions tirées, notamment pour des analyses ultérieures (ex. : corrélations ou modélisation).

Répartition des bateaux par type



Visualisation des données sur une carte

- Affichage de toutes les trajectoires des bateaux



La carte ci-contre représente les trajectoires suivies par différents navires dans le golfe du Mexique, différenciés par type (cargo, tanker, passager, etc.). Elle permet d'identifier plusieurs routes maritimes majeures, révélatrices des flux commerciaux et industriels de la région.

On observe tout d'abord une forte concentration de trajets partant du port de Houston, au Texas, en direction du sud du golfe et des côtes mexicaines. Cette route, empruntée majoritairement par des navires cargos et pétroliers, reflète le rôle central de Houston dans le commerce des hydrocarbures.


Une seconde zone d'activité intense se situe en Louisiane, autour de Baton Rouge et La Nouvelle-Orléans, d'où partent de nombreuses lignes vers le sud-est du golfe, en direction de la Floride ou des plateformes offshore. Ces trajets sont empruntés à la fois par des tankers et des navires passagers, soulignant la diversité d'activités maritimes dans cette région.

La Floride, notamment autour de Miami, constitue un autre pôle important. Des routes relient Miami à la Louisiane et au Texas, formant ainsi un triangle maritime dense entre Houston, La Nouvelle-Orléans et Miami. Ces trajets sont partagés entre navires de croisière et trafic commercial.

Enfin, quelques trajectoires isolées contournent Cuba ou se dirigent vers les Caraïbes, ce qui peut correspondre à des liaisons internationales ou des itinéraires touristiques.

Ces observations mettent en lumière les principaux axes maritimes du golfe du Mexique, dominés par le trafic de marchandises et de pétrole, mais également marqués par la présence de navires passagers dans les zones côtières les plus touristiques.

- **[Affichage de la trajectoire d'un seul bateau par son nom](#)**



La carte ci-dessus illustre la trajectoire d'un navire de type Tanker, spécialisé dans le transport de pétrole ou de produits chimiques, entre deux grands ports du golfe du Mexique. Le navire démarre son trajet dans la région de Houston, au Texas, l'un des plus grands complexes pétrochimiques des États-Unis, puis suit une route maritime en direction de la Nouvelle-Orléans, en Louisiane.

On observe une large boucle en mer, au sud de la Louisiane, avant que le navire n'approche la côte. Ce détour est caractéristique des tankers, qui effectuent parfois des manœuvres d'attente, soit pour des raisons de régulation du trafic, soit pour accéder à des zones de chargement ou déchargement offshore, comme le terminal LOOP (Louisiana Offshore Oil Port).

La fin de la trajectoire montre une entrée dans le delta du Mississippi, où le navire rejoint probablement un terminal portuaire situé près de La Nouvelle-Orléans ou Baton Rouge, zones industrielles majeures connectées au réseau fluvial.

Cette trajectoire met en évidence une route logistique clé pour le transport d'hydrocarbures, reliant deux nœuds stratégiques du golfe du Mexique, tout en illustrant les spécificités de navigation propres aux navires pétroliers.

Etude des corrélations entre variables

Analyse du lien entre les variables grâce aux moyennes

L'objectif de cette analyse est d'identifier les variables pouvant expliquer ou prédire le type de navire (TypeName), c'est l'exemple qu'on a choisi de traiter. Pour cela, nous avons réalisé une analyse bivariée, qui consiste à observer les relations entre deux variables à la fois. Nous avons ici étudié la relation entre le type de navire et trois variables quantitatives disponibles dans notre jeu de données AIS : la longueur (Length), la vitesse sur le fond (SOG) et la largeur (Width).

Nous avons d'abord nettoyé les données afin de ne conserver que les lignes complètes (sans valeurs manquantes sur les variables analysées). Ensuite, nous avons relié chaque code de type de navire (VesselType) à une étiquette explicite (TypeName). Enfin, pour chaque type de navire, nous avons calculé la moyenne de la longueur, de la vitesse et de la largeur.

Type de navire	Longueur moyenne (m)	Vitesse moyenne (nœuds)	Largeur moyenne (m)
Cargo A	305	5,66	38,9
Unknown	189	2,53	31,7
Tanker	185	3,92	31,1
Cargo	152	2,90	25,1
Tanker B	136	4,72	22,0
Passenger A	64	9,72	11,0
Passenger	58,1	3,60	13,6

Ces résultats montrent des profils bien distincts selon le type de navire. Les navires de type Cargo A sont de loin les plus longs et les plus larges, ce qui est cohérent avec leur fonction de transport massif de marchandises. Les Tankers sont également grands mais se déplacent à une vitesse modérée. En revanche, les navires passagers sont beaucoup plus courts, et ceux de la catégorie Passenger A présentent la vitesse moyenne la plus élevée, ce qui reflète leur mission de transport rapide de personnes.

Cette étude bivariée met en évidence que la longueur, la largeur et la vitesse sont des variables significativement différentes selon le type de navire. Ces caractéristiques peuvent donc être considérées comme importantes pour estimer ou prédire le type de bateau. Ces résultats justifient leur utilisation future dans des modèles prédictifs tels que la régression logistique.

Analyse des corrélations entre variables quantitatives

Dans cette section, nous avons étudié les relations entre quatre variables quantitatives issues des données AIS : la longueur (Length), la largeur (Width), la vitesse sur le fond (SOG) et le tirant d'eau (Draft). Pour cela, nous avons calculé les coefficients de corrélation de Pearson, qui mesurent l'intensité et le sens des relations linéaires entre deux variables.

Le coefficient de corrélation de Pearson est un indicateur statistique qui permet de mesurer la force et le sens de la relation linéaire entre deux variables quantitatives. Il est noté r et sa valeur est toujours comprise entre -1 et $+1$.

- Une valeur de r proche de $+1$ indique une corrélation linéaire positive forte : lorsque l'une des variables augmente, l'autre a tendance à augmenter également.
- Une valeur de r proche de -1 indique une corrélation linéaire négative forte : lorsque l'une des variables augmente, l'autre diminue.
- Une valeur de r proche de 0 signifie qu'il n'y a pas de relation linéaire apparente entre les deux variables.

Le coefficient de Pearson est calculé à partir des écarts des valeurs de chaque variable par rapport à leur moyenne. Plus les valeurs suivent une tendance linéaire (montante ou descendante), plus la corrélation sera forte.

On obtient la matrice de corrélation suivante:

	Length	Width	SOG	Draft
Length	1.00	0.95	0.15	0.85
Width	0.95	1.00	0.11	0.83
SOG	0.15	0.11	1.00	0.11
Draft	0.85	0.83	0.11	1.00

Les résultats montrent une corrélation très forte et positive entre la longueur et la largeur des navires ($r = 0,95$), ce qui est cohérent puisque

les plus grands navires sont également plus larges pour des raisons de stabilité. De même, on observe une forte corrélation entre la longueur et le tirant d'eau (distance verticale entre la ligne de flottaison et le fond de la coque du navire) ($r = 0,85$), ainsi qu'entre la largeur et le tirant d'eau ($r = 0,83$). Ces trois variables sont donc liées entre elles et caractérisent la taille globale d'un navire.

En revanche, la vitesse sur le fond (SOG) n'est que très faiblement corrélée aux autres variables (coefficients compris entre 0,11 et 0,15). Cela signifie que la vitesse d'un navire n'est pas directement déterminée par ses dimensions physiques, mais plutôt par d'autres facteurs comme sa fonction, son statut de navigation ou sa charge.

Cette analyse met en évidence une redondance structurelle entre la longueur, la largeur et le tirant d'eau, ce qui peut être utile pour réduire le nombre de variables dans un modèle prédictif. En revanche, la variable SOG apporte une information indépendante, potentiellement complémentaire pour caractériser le comportement du navire.

Étude des relations entre variables qualitatives (analyse bivariée)

L'objectif de cette étape est d'identifier s'il existe des liens significatifs entre les variables qualitatives de notre jeu de données AIS, et plus particulièrement avec le type de navire (TypeName). Pour cela, nous avons conduit des analyses bivariées sous forme de tableaux croisés, accompagnées de tests d'indépendance du χ^2 .

Ce type d'analyse permet de déterminer si deux variables sont statistiquement dépendantes, c'est-à-dire si l'une peut influencer ou expliquer l'autre.

- ◆ Exemple 1 : Type de navire (TypeName) vs Type de cargaison (Cargo)

Dans cette première analyse, nous avons croisé le type de navire avec la variable Cargo, qui décrit le type de cargaison transportée à l'aide de codes s.

Résultat du test du χ^2 : X-squared = 790866, df = 96, p-value < 2.2e-16

La p-value extrêmement faible (< 0.05) indique que nous rejetons l'hypothèse d'indépendance entre ces deux variables. Autrement dit, il existe une dépendance forte entre le type de navire et le type de cargaison transportée.

Cela semble cohérent : un tanker ne transporte pas la même cargaison qu'un navire de pêche ou un navire à passagers. Ce lien, désormais validé statistiquement, montre que la variable Cargo peut être utile pour expliquer ou prédire le type de navire.

◆ Exemple 2 : Type de navire (TypeName) vs Statut de navigation (Status)

Dans cette deuxième analyse, nous avons croisé le type de navire avec son statut de navigation (Status), qui indique s'il est en mouvement, à l'ancre, à quai, etc.

Résultat du test du χ^2 : X-squared = 68572, df = 36, p-value < 2.2e-16

Là encore, la p-value est extrêmement faible, ce qui indique une dépendance significative entre le type de navire et son statut de navigation.

En pratique, cela signifie que certains types de navires adoptent des comportements spécifiques. Par exemple, les navires de passagers sont souvent en navigation, tandis que les tankers ou cargos passent plus de temps à l'arrêt ou à quai.

Cette information est pertinente pour comprendre le comportement des navires et pour la prédiction des positions des navires.

Analyse de tableaux croisés

Après avoir obtenu une p-value extrêmement faible lors du test du χ^2 entre le type de navire (TypeName) et le statut de navigation (Status), nous avons examiné en détail le tableau croisé correspondant. Ce tableau permet de visualiser le nombre de navires par type pour chaque statut de navigation (en mouvement, à l'ancre, à quai, etc.).

Extrait du tableau croisé :

Type de navire	Status 0 (En route)	Status 1 (À l'ancre)	Status 3 (À quai)	Status 5	Status 8	Status 15
Cargo	52 289	14 524	0	18 800	0	0
Cargo A	3 907	575	0	970	0	0
Passenger	21 039	0	0	1 038	4 522	4 905
Passenger A	1 399	0	0	441	0	0
Tanker	27 249	19 776	1 895	17 158	3 954	0
Tanker B	1 128	902	0	481	0	0
Unknown	3 933	4 833	0	1 738	1 604	0

L'analyse de ce tableau met en évidence des comportements spécifiques selon les types de navires :


- Les navires de type Cargo et Tanker sont principalement en statut 0 (en route) ou en statut 5, probablement à quai ou dans une situation opérationnelle. On note également une forte proportion de tankers en statut 1 (à l'ancre), ce qui est cohérent avec leur fonctionnement, car ils attendent souvent une place au port ou un créneau de déchargement.
- Les navires de type Passenger présentent un profil différent, avec une forte proportion en statut 0, ce qui montre qu'ils sont majoritairement en déplacement. On observe également beaucoup de passagers en statuts 8 et 15, qui correspondent à des situations spécifiques (p. ex. manœuvres spéciales ou inconnues).
- Les navires de type Unknown montrent une répartition plus diffuse mais restent cohérents avec les profils observés pour d'autres navires en navigation ou à l'ancre.

Ce tableau confirme visuellement ce que le test du χ^2 a démontré : le statut de navigation est fortement dépendant du type de navire.


Chaque catégorie de navire présente des comportements propres qui peuvent être analysés pour mieux comprendre leur fonctionnement, mais aussi pour alimenter un modèle prédictif visant à estimer le type de navire à partir de données comportementales.

Analyse des relations entre les variables qualitatives : Mosaic Plots


Mosaic Plot: Cargo vs Status



Mosaic Plot: VesselType vs Cargo



Mosaic Plot: Cargo vs Status



Pour explorer les relations entre les variables qualitatives du dataset export_IA.csv, des mosaic plots ont été générés à l'aide de R avec la bibliothèque tidyverse. Ces graphiques illustrent la répartition des fréquences entre les paires de variables : VesselType et Status, VesselType et Cargo, et Cargo et Status.

- **Mosaic Plot : VesselType et Status** : son graphique met en évidence la distribution des types de bateaux selon leur statut. Les rectangles de tailles variables indiquent une concentration notable de certains statuts (ex. : 0, 15, 8) pour des types de bateaux spécifiques, suggérant une possible association entre ces variables.
- **Mosaic Plot : Cargo et Status** : la visualisation montre la relation entre les types de cargaison et les statuts. Les différences de proportions observées, notamment pour les statuts 0 et 15, laissent présumer une dépendance entre Cargo et Status.
- **Mosaic Plot: Cargo et vesseltype**: Un mosaic plot a été utilisé pour analyser la relation entre le type de bateau (VesselType) et le type de cargaison (Cargo) dans le dataset. Le graphique montre une forte association entre certains types, comme la catégorie 60 et la cargaison 70 (rectangles larges), tandis que les combinaisons avec les catégories 67 ou 49 sont moins fréquentes (rectangles plus petits). Les variations de taille et de couleur suggèrent une possible dépendance, bien qu'un test du χ^2 soit nécessaire pour la confirmer.

CONCLUSION

Ce projet Big Data nous a permis d'explorer et d'analyser en profondeur un jeu de données issu du système d'identification automatique (AIS) des navires. Après un important travail de nettoyage des données brutes, nous avons pu produire des visualisations claires et informatives, à la fois sous forme de graphiques et de cartes, afin de mieux comprendre les comportements des navires dans le golfe du Mexique.

L'étude des ports les plus fréquentés a mis en évidence des pôles maritimes majeurs comme Houston, Fourchon ou Galveston, tandis que la visualisation des trajectoires a permis d'identifier les routes maritimes dominantes empruntées par différents types de navires. Grâce aux analyses statistiques, nous avons démontré que certaines

caractéristiques physiques (longueur, largeur, tirant d'eau) sont fortement corrélées entre elles, alors que d'autres, comme la vitesse, dépendent davantage de facteurs contextuels.

L'analyse des relations entre variables qualitatives, via des tableaux croisés et des tests du χ^2 , a confirmé l'existence de liens significatifs entre le type de navire, le type de cargaison transportée et le statut de navigation. Ces résultats sont essentiels pour la construction de futurs modèles prédictifs visant, par exemple, à estimer automatiquement le type de navire à partir de données AIS.

En combinant des compétences en traitement de données, en visualisation et en statistiques, ce projet nous a permis d'aborder une problématique concrète liée à l'analyse des flux maritimes dans le golfe du Mexique, de mieux comprendre le comportement des navires et d'identifier les zones portuaires et les itinéraires les plus stratégiques à partir de données réelles issues du système AIS.